

MAISA · HACKSPAIN 2026

ETSIT UPM · MADRID

Reto · 500 Sombras de Alberto

ALBERTITOS

Del PDF a la decisión, con evidencia

FACTURA



DECISIÓN



TRAZA

GRUPO DE USUARIOS DE LINUX · UC3M

Luis Daniel Casais · Albert Giurgiu · Jorge Saghin · Henry Díaz

01 - DEMO Y CONTEXTO

DASHBOARDINGESTINVOICESREVIEWLOGS

Revisar 26 pendientesPREPARANDO VLM...Configuración

El VLM local aún no está preparado.

Start VLM

Dashboard

Facturas pendientes

27

O en revisión (sin decisión) · 27 escaladas

• 27 PDF

actualizado 10:19:00

Resumen

PAGAR

438

NO_PAGAR

35

ESCALAR

27

PENDIENTE

0

RETENIDAS

26


ABIERTAS (27)

RESUELTAS (473)

NOMBRE	ARCHIVO	ITERACIONES	CONFIANZA	DECISIÓN	ACCIONES
2026-03-10_P008.pdf	PDF	2	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
F26-8812_electricidad.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-1123_construcciones.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-2967_seguridad.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-4298_mensajería.pdf	PDF	2	—	ESCALAR Aceptar Corregir	Ver Logs
FA-5044_mensajería2.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-5632_transportes.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-7311_transportes.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
FA-9104_electricidad.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
copia_2026_0518.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
fax_2026_0411.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
reimpresion_0712.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs
scan_0804.pdf	PDF	1	—	RETENIDA ESCALAR Aceptar Corregir	Ver Logs

02 - ARQUITECTURA Y ADRS

ARQUITECTURA GENERAL



◀ evidencia de cada fase

▼ sirve candidatos e imágenes

ALMACÉN

CosmosDB: Evidencias, decisiones, resultados. Datos históricos, configuraciones y datos maestros

INTERFAZ

FastAPI + Svelte. Consulta de datos históricos y cola de ESCALAR para revisión humana

Se pueden añadir reglas sin modificar la extracción, y un tipo de archivo sin tocar el motor. Además, cada peldaño se puede omitir y la caché es por página.

PASOS PARA LA EXTRACCIÓN

1	Texto Vectorial (pypdf + Plausibilidad) Filtro ortográfico y alfanumérico anti-mojibake CID	< 1 MS 0 €
▼ <i>degrada al siguiente escalón</i>		
2	Rasterizado y QR (pypdfium2 + zxing) 300 DPI. Si la página es solo QR, payload = contenido	40 MS 0 €
▼ <i>degrada al siguiente escalón</i>		
3	Tesseract OCR (Doble Puerta) Pasa solo con word-conf > 40% y cobertura campos > 0.4	150 MS 0 €
▼ <i>degrada al siguiente escalón</i>		
4	VLM Local (PaddleOCR-VL 1.6 Q8 + OpenCV) Contexto 131k, KV q8_0, unsharp masking en escaneos	1.7 S 0 €
▼ <i>degrada al siguiente escalón</i>		
5	TypeSafe System One (Jev-latest) Decisiones tipadas y probabilidades paralelas (noul/choice/score)	560 MS 0.04 \$ / MTOK
▼ <i>degrada al siguiente escalón</i>		
6	Firecrawl Document Parsing (/v2/parse) Rescate de tablas complejas y PDFs a Markdown estructurado	1.2 S 1 CREDIT
▼ <i>degrada al siguiente escalón</i>		
7	Cloud VLM (>25B Multimodal OpenAI comp.) Último recurso. Lectura como candidato extra (sin auto-stop)	3 S PAGO TOKEN

FEATURES CRUDAS, CAMPOS CON CANDIDATOS

EXTRACCIÓN · FEATURES

- texto, imagen, QR, tabla
- material crudo, sin interpretar
- motor + versión + latencia + hash

PARSER · FIELDS

- NIF, IBAN, total, IVA, fecha, pedido
- **todos** los candidatos en `values[]`
- cada uno con extractor y confianza `[0,1]`

Un campo **nunca** se colapsa en el store. El escalar se elige solo en la regla que lo consume, y queda registrado **cuál** y **por qué**:



Parser multilingüe (7 idiomas) · inmune a trampas OCR · prioriza el NIF del proveedor sobre el CIF del cliente.

EL MOTOR: PURO, DETERMINISTA, CONFIGURABLE

Reglas en código, con *thresholds* configurables

```
NIF_IN_MASTER · IBAN_MATCHES_MASTER  
ORDER_BELONGS_TO_SUPPLIER · ORDER_PENDING  
NO_DOUBLE_PAYMENT · IVA_CONSISTENT  
TOTALS_MUST_MATCH · DATE_VALID_NOT_FUTURE
```

- FAIL ⇒ outcome **más restrictivo** (NO_PAGAR / ESCALAR, dependiente de la regla).
- UNKNOWN (o sin reglas) ⇒ **ESCALAR**: duda razonable.
- Todas PASS ⇒ **PAGAR**

Salida: **evaluación + snapshot**

```
{  
  "result": "ESCALAR",  
  "rule_verdicts": [  
    {"rule": "TOTALS_MUST_MATCH", "verdict": "PASS", "values":  
    {...}},  
    {"rule": "NIF_IN_MASTER", "verdict": "UNKNOWN", "reason":  
    "sin candidato"}  
  ],  
  "snapshot": {"rule_set": "v1", "thresholds": {...},  
    "extractors": {...}, "master_sha256": "9f2c..."  
}
```

Umbrales, reglas habilitadas y: **configuración versionada**.
El maestro se sella por **sha256**; el ERP, por interfaz intercambiable.

Mismos campos + misma config ⇒ misma decisión.

CUATRO ADRS (1/2) - MOTOR Y EXTRACCIÓN

ADR-01 - MOTOR DE REGLAS DETERMINISTA



Reglas en código, **puras y deterministas**; umbrales y política como configuración versionada, con **snapshot** en cada decisión. Añadir una regla no toca la extracción; cambiar la política exige ADR.

ADR-02 - EXTRACCIÓN EN DOS BLOQUES



Features tipadas + parser que produce campos con **valores múltiples** (extractor y confianza). Umbrales del peldaño 3 calibrados con el corpus: el **94,2 %** resuelve por texto.

Cada ADR lleva contexto, alternativas, decisión, consecuencias y **evidencia medida**. Detalle en [albertitos_plan.pdf](#).

CUATRO ADRS (2/2) · PIPELINE Y ALMACÉN

ADR-03 · PIPELINE DESACOPLADA ■

Colas entre extracción, parser y decisión: cada bloque escala y falla por separado. El ERP, solo por **costura de adaptador**; reanudación **sin duplicados**.

ADR-04 · ALMACÉN POUCHDB + COUCHDB ■

PouchDB embebido como única persistencia, con adjuntos fragmentados y **replicación nativa** a CouchDB. Sin **joins** ni transacciones: consistencia por IDs deterministas y conflictos **fail-closed**.

El histórico y los candidatos viven en el almacén; la regla v4 del lote 2 llega como **datos**, sin tocar el motor.

03 - TRAZABILIDAD, ESCALA Y COSTE

El estado vive en disco; los números, medidos

- Cada factura tiene un **UUID**; `file_id` es el nombre exacto del PDF.
- **PouchDB local (LevelDB)**: decisiones inmutables, candidatos sin colapsar, adjuntos fragmentados. En servidor, réplica nativa **PouchDB ↔ CouchDB**; la config local no se replica.
- **Idempotente y resumible**: clave `(sha256, etapa, engine_version, config_version)`; re-procesar es un no-op.

Cada etapa escribe una fila de evidencia:

```
invoice_id · stage · extractor · extractor_version · config_version  
sha256 · latency_ms · confidence · outcome · detail
```

La cola de revisión guarda la corrección humana como **override con provenance** (quién, cuándo, antes/después); afecta solo a la extracción y el motor recalcula. Es el corpus de reentrenamiento.

ESCALA: HAGAMOS LAS CUENTAS

500

PDFS DEL LOTE 1

4,16

ARCHIVOS/S END-TO-END

2,3 S

LATENCIA MEDIA / FACTURA

EL LOTE ENTERO

$500 \div 4,16 \approx 120 \text{ s} \rightarrow \approx 2 \text{ min}$ por lote. Peldaño 1
medido a **2 636 archivos/s**.

DÓNDE SE VA EL TIEMPO

$471 / 500 = 94,2 \%$ resuelve por texto. Solo $29 = 5,8 \%$
baja a raster / OCR / VLM.

UI + 2 runners en paralelo: peor **p95 7,7 ms**, **109 archivos/s por runner**, 0 incidencias. Hardware medido: **4 núcleos · 8q GB**.

COSTE: HAGAMOS LAS CUENTAS

```
coste_lote = CPU_local + llamadas_cloud + tokens_agentes  
CPU local = 0,0000 € (medido) · llamadas cloud = 0,0000 € (medido)
```

LO QUE CUESTA

Rung 5 TypeSafe: 0,04 \$ / Mtok. Rung 6 Firecrawl:
1 crédito. Rung 7: pago por token.

LO QUE SE PAGA

471 páginas resuelven **gratis** por texto. Solo las que caen a la nube pagan, y quedan **cacheadas por página**.

En el lote medido cayó **1 página** a la nube $\Rightarrow$ coste marginal $\approx$ **0 €**. Estimación de cola:

$5\ 000\ \text{tok} \times 0,04\ \$/\text{Mtok} \approx 0,0002\ \$/\text{página}$; 500 páginas difíciles $\approx$ **0,10 \$**, y con caché re-ejecutar es gratis.

LOTE 1, AUDITADO

433

PAGAR

22

NO_PAGAR

45

ESCALAR

LA AUDITORÍA ENCONTRÓ LA TRAMPA

El motor colapsaba `total` al **primer** candidato — «Subtotal» en vez de «TOTAL A PAGAR»: **87 NO_PAGAR eran falsos**. ADR-O2: ahora las reglas evalúan **todos** los candidatos con provenance. Reprocesado: $347 + 86 = 433$ PAGAR y $108 - 86 = 22$ NO_PAGAR, **0 regresiones. 86,6 % PAGAR** automático.

04 • RESILIENCIA Y PREGUNTAS

Degrada, no se detiene

RESILIENCIA PROBADA

PROVEEDOR CAÍDO



3 intentos → revisión; el lote sigue. **PASS**

CRASH + REANUDACIÓN



Reanudación completa; **0 duplicados**. **PASS**

BACKOFF 429



Retry-After respetado; 0 llamadas extra. **PASS**

LEDGER CORRUPTO



El histórico sobrevive; recuperable. **PASS**

4 / 4 drills medidos en PASS. Un peldaño que falta no para el lote: `skipped:<razón>` y el veredicto honesto es **ESCALAR**.

Medido en la corrida: 22 reintentos, 3 omisiones y **0 errores de proveedor**.

FUTURO: LO QUE VIENE

LOTE 2 • REGLA V4

Cargada como **datos** en `rules.yaml`; el motor no cambia.

ERP REAL

Conectar el ERP por la costura de adaptador, sin tocar reglas ni extracción.

CORPUS DE ESCALADOS

Los casos revisados alimentan reentrenamiento y umbrales.

MÁS ADMINISTRACIONES

El parser ya cubre 7 idiomas; añadir reglas fiscales por país.

Y el panel de **salud y coste**: coste por página, proveedor y peldaño, visible mientras el lote corre.

¿PREGUNTAS?

[GITHUB.COM/GULUC3M/HACKSPAIN26](https://github.com/GULUC3M/HACKSPAIN26)